

## 2.2. Modele ARMA – Modele staționare liniare pentru Analiza Seriilor de Timp

**Un proces autoregresiv (AR)** este un proces unde valoarea curentă a lui  $y$  este influențată de propriile valori din trecut și de o perturbare  $\varepsilon_t$ . Variabila aleatoare  $\varepsilon_t$  este numită și **inovație**, deoarece reprezintă partea nepredictibilă a valorilor variabilei  $y_t$ , date fiind valorile anterioare  $y_{t-1}, y_{t-2}, \dots$ .

**Un proces de medie mobilă (MA)** este un proces unde valoarea curentă (contemporană) a lui  $y$  este influențată atât de valoarea contemporană cât și de valorile din trecut ale termenului inovație  $\varepsilon_t$ .

$$\text{AR}(1): y_t = \phi y_{t-1} + \varepsilon_t$$

$$\text{MA}(1): y_t = \varepsilon_t + \theta \varepsilon_{t-1}$$

$$\text{AR}(p): y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$$

$$\text{MA}(q): y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

Vom folosi modele de medie zero. Acestea reprezintă abateri ale seriei de la medie. De exemplu, dacă o serie are media  $\mu$  și urmează un proces AR(1), atunci relația

$$(y_t - \mu) = \phi(y_{t-1} - \mu) + \varepsilon_t \text{ este echivalentă cu relația } y_t = (1 - \phi)\mu + \phi y_{t-1} + \varepsilon_t$$

Astfel, constantele pot include mediile. În general, vom lucra cu modele de medie zero, deoarece este ușor să se adauge mediile sau trendurile deterministe.

### **Procese liniare**

Considerăm un model simplu, modelul autoregresiv definit prin:

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad t = 2, 3, \dots, n,$$

unde parametrul  $\phi$  este o constantă cu proprietatea că  $|\phi| < 1$ , iar  $\varepsilon_t$  reprezintă un șir de variabile aleatoare necorelate, fiecare cu media 0 și varianța  $\sigma^2$ .

Pentru a vedea dacă există o serie  $y_t$  care verifică relația de mai sus, vom scrie modelul cu ajutorul operatorului lag. Vom avea  $y_t - \phi y_{t-1} = \varepsilon_t$ , deci  $(1 - \phi L)y_t = \varepsilon_t$ .

Inversând formal această relație obținem soluția:

$$y_t = (1 - \phi L)^{-1} \varepsilon_t = (1 + \phi L + \phi^2 L^2 + \dots) \varepsilon_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots = \sum_{k=0}^{\infty} \phi^k \varepsilon_{t-k}$$

### **Teorema de descompunere a lui Wold**

Orice proces stochastic slab staționar și absolut nedeterminist ( $y_t - \mu$ ) poate fi reprezentat ca o combinație liniară (sau filtru liniar) de variabile aleatoare necorelate.

$$y_t - \mu = \varepsilon_t + \psi_1 \varepsilon_{t-1} + \psi_2 \varepsilon_{t-2} + \dots = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} \quad \text{cu } \psi_0 = 1 \text{ și } \sum_{j=0}^{\infty} \psi_j^2 < \infty.$$

$\{\varepsilon_t\}$  este un proces de zgomot alb (white noise), adică un șir de variabile aleatoare independente, identic distribuite, cu media 0 și varianța  $\sigma^2$ . Acesta se notează sub forma  $\varepsilon_t \sim WN(0, \sigma^2)$ .

### **Modelul de medie mobilă de ordinul întâi, MA(1)** Este de forma:

$$y_t = \varepsilon_t + \theta \varepsilon_{t-1}$$

$\theta$  este orice constantă, iar  $\{\varepsilon_t\}$  este un proces de zgomot alb, deci  $\varepsilon_t \sim WN(0, \sigma^2)$ .

Cerințe: Să se determine media, varianța, autocovarianțele și funcția de autocorelație ale lui  $y_t$ .

Media lui  $y_t$  este:  $E(y_t) = E(\varepsilon_t) + \theta E(\varepsilon_{t-1}) = 0$ .

Varianța lui  $y_t$  este:

$$\text{Var}(y_t) = \gamma_0 = E(\varepsilon_t + \theta \varepsilon_{t-1})^2 = E(\varepsilon_t^2 + 2\theta \varepsilon_t \varepsilon_{t-1} + \theta^2 \varepsilon_{t-1}^2) = (1 + \theta^2) \sigma^2.$$

Autocovarianța la lag-ul 1 este:

$$\gamma_1 = \text{cov}(y_t, y_{t-1}) = E(y_t y_{t-1}) = E(\varepsilon_t + \theta \varepsilon_{t-1})(\varepsilon_{t-1} + \theta \varepsilon_{t-2}) =$$

$$= E(\varepsilon_t \varepsilon_{t-1} + \theta \varepsilon_{t-1}^2 + \theta \varepsilon_t \varepsilon_{t-2} + \theta^2 \varepsilon_{t-1} \varepsilon_{t-2}) = \theta \sigma^2$$

Autocovarianța la lag-ul 2 este:

$$\gamma_2 = \text{cov}(y_t, y_{t-2}) = E(y_t y_{t-2}) = E(\varepsilon_t + \theta \varepsilon_{t-1})(\varepsilon_{t-2} + \theta \varepsilon_{t-3}) = \\ E(\varepsilon_t \varepsilon_{t-2} + \theta \varepsilon_{t-1} \varepsilon_{t-2} + \theta \varepsilon_t \varepsilon_{t-3} + \theta^2 \varepsilon_{t-1} \varepsilon_{t-3}) = 0.$$

Rezultă că autocovarianțele de lag  $k > 1$  sunt zero:  $\gamma_k = 0$ .

**Un proces MA(1) este staționar**, indiferent de valoarea lui  $\theta$ , deoarece media și autocovarianțele nu sunt funcții de timp.

**Funcția de autocorelație (ACF) a unui proces MA(1) este:**

$$\rho_0 = 1; \quad \rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{\theta \sigma^2}{(1 + \theta^2) \sigma^2} = \frac{\theta}{1 + \theta^2}; \quad \rho_k = 0, \quad k > 1.$$

$$\gamma_k = \begin{cases} (1 + \theta^2) \sigma^2, & k = 0 \\ \theta \sigma^2, & k = 1 \\ 0, & k > 1 \end{cases} \Rightarrow \rho_k = \begin{cases} 1, & k = 0 \\ \frac{\theta}{1 + \theta^2}, & k = 1 \\ 0, & k > 1 \end{cases}$$

*Observație:* Un șoc într-un proces MA(1) afectează  $y_t$  numai în două momente de timp.

*Memoria procesului MA(1) este doar de o perioadă.* Procesul MA se numește de memorie scurtă.

Autocorelația de ordin  $k$  poate fi reprezentată grafic ca o funcție de  $k$ , rezultând corelograma procesului. Pentru valori diferite ale lui  $\theta$  se obțin valori diferite ale lui  $\rho_1$ .

Dacă  $\theta$  este pozitiv, rezultă  $\rho_1$  pozitiv. Dacă  $\theta$  este negativ, rezultă  $\rho_1$  negativ.

Cea mai mare valoare pentru  $\rho_1$  este 0,5 și apare când  $\theta = 1$ .

Cea mai mică valoare a lui  $\rho_1$  este  $-0,5$ . Această valoare apare dacă  $\theta = -1$ . Pentru orice valoare a lui  $\rho_1$  între  $-0,5$  și  $0,5$ , există două valori ale lui  $\theta$  care ar putea produce acea autocorelație. Aceasta se întâmplă deoarece

valoarea  $\rho_1 = \frac{\theta}{1 + \theta^2}$  rămâne neschimbată dacă se înlocuiește  $\theta$  prin  $1/\theta$ . În acest mod rezultă că întotdeauna se

pot găsi două procese MA(1) care au aceeași funcție de autocorelație. Se impune condiția de inversabilitate pentru a ne asigura că există un model MA unic, pentru o ACF dată.

### **Inversabilitatea procesului MA(1)**

Dacă folosim operatorul de întârziere, sau operatorul lag,  $L$ , vom putea scrie modelul MA(1):

$$y_t = \varepsilon_t + \theta \varepsilon_{t-1} \text{ sub forma } y_t = (1 + \theta L) \varepsilon_t.$$

Procesul MA este inversabil când rădăcina **polinomului de medie mobilă**  $\Theta(L) = 1 + \theta L = 0$  se află în afara cercului unitate, adică avem  $|1/\theta| > 1$ . Aceasta implică condiția pentru parametru:  $-1 < \theta < 1$ .

Procesul este inversabil dacă rădăcina ecuației  $\Theta(z) = 1 + \theta z = 0$  este în afara cercului unitate, adică avem  $|z| > 1$  sau echivalent,  $|\theta| < 1$ .

### **Reprezentarea procesului MA(1) sub forma unui proces AR( $\infty$ ).**

Fie procesul  $y_t = (1 + \theta L) \varepsilon_t$ .

Considerăm reprezentarea autoregresivă  $y_t = \pi_1 y_{t-1} + \pi_2 y_{t-2} + \pi_3 y_{t-3} + \dots + \varepsilon_t$ ,  $\varepsilon_t \sim WN(0, \sigma^2)$ .

Pentru a obține o reprezentare autoregresivă convergentă trebuie impusă condiția  $|\theta| < 1$ . Aceasta reprezintă **condiția de inversabilitate** a polinomului de medie mobilă  $\Theta(L) = (1 + \theta L)$ .

$(1 - \pi_1 L - \pi_2 L^2 - \pi_3 L^3 - \dots) y_t = \varepsilon_t$ . Ponderile  $\pi_j$  se calculează din identitatea:

$(1 - \pi_1 L - \pi_2 L^2 - \pi_3 L^3 - \dots)(1 + \theta L) = 1$ . Prin identificarea coeficienților lui  $L^j$ , se obțin ponderile  $\pi_j$ . Aceste ponderi converg dacă  $|\theta| < 1$ . Rezultă că un proces stochastic staționar autoregresiv infinit pentru  $y_t$  poate fi rescris ca o sumă ponderată a unui proces zgomot alb și deci, ca un proces de medie mobilă. Oricărui model de medii mobile îi corespunde o reprezentare prin filtru liniar cu un număr finit de ponderi.

O condiție necesară ca un proces MA să fie reprezentat ca un proces AR( $\infty$ ) este ca procesul MA să fie inversabil. Reprezentarea MA este convenabilă pentru a calcula varianțele și covarianțele seriei. Reprezentarea AR este convenabilă pentru a face previziuni cu privire la serie.

### **Modelul de medie mobilă de ordinul doi, MA(2)**

Fie  $\theta_1, \theta_2 \in \mathbb{R}$ , cu  $\theta_2 \neq 0$  și fie  $\varepsilon_t \sim WN(0, \sigma^2)$ , zgomot alb. Atunci procesul

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$

se spune că este un proces de medie mobilă de ordinul 2 și se notează MA(2).

*Cerințe:* Să se determine media, varianța, autocovarianțele și funcția de autocorelație ale lui  $y_t$ .

Pentru un proces MA(2), se obțin următoarele valori:

$$E(y_t) = E(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}) = E(\varepsilon_t) + \theta_1 E(\varepsilon_{t-1}) + \theta_2 E(\varepsilon_{t-2}) = 0$$

$$\gamma_0 = \text{Var}(y_t) = E(y_t^2) = E(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})^2 = \dots = (1 + \theta_1^2 + \theta_2^2) \sigma^2$$

$$\gamma_1 = \text{Cov}(y_t, y_{t-1}) = E(y_t y_{t-1}) = E(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_{t-1} + \theta_1 \varepsilon_{t-2} + \theta_2 \varepsilon_{t-3}) = (\theta_1 + \theta_1 \theta_2) \sigma^2$$

$$\gamma_2 = \text{Cov}(y_t, y_{t-2}) = E(y_t y_{t-2}) = E(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2})(\varepsilon_{t-2} + \theta_1 \varepsilon_{t-3} + \theta_2 \varepsilon_{t-4}) = \theta_2 \sigma^2$$

$$\gamma_3 = \text{Cov}(y_t, y_{t-3}) = E(y_t y_{t-3}) = 0$$

$$\gamma_k = \begin{cases} (1 + \theta_1^2 + \theta_2^2) \sigma^2, & k = 0 \\ (\theta_1 + \theta_1 \theta_2) \sigma^2, & k = 1 \\ \theta_2 \sigma^2, & k = 2 \\ 0, & k > 2 \end{cases} \Rightarrow \rho_k = \begin{cases} 1, & k = 0 \\ (\theta_1 + \theta_1 \theta_2) / (1 + \theta_1^2 + \theta_2^2), & k = 1 \\ \theta_2 / (1 + \theta_1^2 + \theta_2^2), & k = 2 \\ 0, & k > 2 \end{cases}$$

Cu ajutorul operatorului lag  $L$ , vom scrie modelul sub forma  $y_t = (1 + \theta_1 L + \theta_2 L^2) \varepsilon_t = \Theta(L) \varepsilon_t$ , unde  $\Theta(L) = (1 + \theta_1 L + \theta_2 L^2)$  este polinomul de medie mobilă de ordinul doi.

Notăm cu  $\lambda_1, \lambda_2$  rădăcinile ecuației  $P(\lambda) = (\lambda^2 + \theta_1 \lambda + \theta_2) = 0$ . Polinomul de medie mobilă poate fi factorizat, astfel încât obținem ecuația  $\Theta(z) = (1 + \theta_1 z + \theta_2 z^2) = (1 - \lambda_1 z)(1 - \lambda_2 z) = 0$ .

Condiția de inversabilitate este îndeplinită dacă rădăcinile  $\lambda_1, \lambda_2$  satisfac condițiile  $|\lambda_1| < 1$  și  $|\lambda_2| < 1$ , ceea ce este echivalent cu  $|z_1| > 1$  și  $|z_2| > 1$ .

Cei doi parametri  $\theta_1$  și  $\theta_2$  ai modelului satisfac următoarele condiții:

$$\theta_1 + \theta_2 > -1, \theta_2 - \theta_1 > -1 \text{ și } |\theta_2| < 1.$$

**Reprezentarea procesului MA(2) sub forma unui proces AR( $\infty$ ).** Fie  $y_t = (1 + \theta_1 L + \theta_2 L^2) \varepsilon_t$ .

Considerăm reprezentarea  $y_t = \pi_1 y_{t-1} + \pi_2 y_{t-2} + \pi_3 y_{t-3} + \dots + \varepsilon_t$ , cu  $\varepsilon_t \sim WN(0, \sigma_\varepsilon^2)$ . O formă echivalentă este  $(1 - \pi_1 L - \pi_2 L^2 - \pi_3 L^3 - \dots) y_t = \varepsilon_t$ . Ponderile  $\pi_j$  se calculează din identitatea

$(1 - \pi_1 L - \pi_2 L^2 - \pi_3 L^3 - \dots)(1 + \theta_1 L + \theta_2 L^2) = 1$ . Prin identificarea coeficienților lui  $L^j$ , se obțin ponderile:  $\pi_1 = \theta_1$ ,  $\pi_2 = -\theta_1 \pi_1 + \theta_2 = \theta_2 - \theta_1^2$ , rezultând  $\pi_j = -\theta_1 \pi_{j-1} - \theta_2 \pi_{j-2}$ , pentru  $j > 2$ .

### **Modelul de medie mobilă de ordinul q, notat MA(q):**

Fie  $\theta_1, \theta_2, \dots, \theta_q \in \mathbb{R}$ , cu  $\theta_q \neq 0$  și fie  $\varepsilon_t \sim WN(0, \sigma^2)$ , zgomot alb. Atunci procesul

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

se spune că este un proces de medie mobilă de ordinul q și se notează MA(q).

Putem rescrie sub forma:  $y_t = \Theta(L) \varepsilon_t$ , unde

$$\Theta(L) = (1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q)$$
 este polinomul de medie mobilă de ordinul q.

Un proces MA este staționar deoarece orice două elemente  $y_t$  și  $y_s$  reprezintă aceeași funcție de vectorii  $(\varepsilon_t, \varepsilon_{t-1}, \dots, \varepsilon_{t-q})$  și  $(\varepsilon_s, \varepsilon_{s-1}, \dots, \varepsilon_{s-q})$  care sunt identic distribuiți.

Ne interesează un proces MA inversabil. Când un proces este inversabil, înseamnă că este posibil să se exprime valoarea curentă a variabilei  $y_t$  cu ajutorul șocului curent  $\varepsilon_t$  și al valorilor ei întârziate  $y_{t-1}, y_{t-2}, \dots$ . Atunci, se spune că modelul are o reprezentare autoregresivă. În acest fel se pot asocia evenimente din prezent cu ce s-a întâmplat în trecut.

### Procese inversabile

Un proces MA(q) nu este unic determinat prin funcția sa de autocorelație. În scopul obținerii unei relații unice între procesele de MA și ACF, Box și Jenkins au introdus condiția de inversabilitate. Aceasta este utilă pentru procedurile de estimare când un proces MA(q) va fi estimat din funcția de autocorelație empirică.

Procesul MA(q),  $y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$ , cu  $\theta_q \neq 0$ , se spune că este inversabil dacă toate rădăcinile  $z_1, z_2, \dots, z_q \in \mathbb{C}$ , ale ecuației  $\Theta(z) = (1 + \theta_1 z + \theta_2 z^2 + \dots + \theta_q z^q) = 0$  se află în afara cercului unitate, adică avem  $|z_i| > 1$ , pentru  $1 \leq i \leq q$ .

**Condiția de inversabilitate pentru un model MA(q):** Un model, MA(q) este inversabil dacă cele  $q$  rădăcini ale ecuației caracteristice  $\Theta(z) = (1 + \theta_1 z + \theta_2 z^2 + \dots + \theta_q z^q) = 0$  se află în afara cercului unitate ( $|z| > 1$ ). În acest caz se spune că polinomul  $\Theta(z)$  este inversabil iar procesul MA(q) poate fi scris ca un proces AR( $\infty$ ), în mod unic. Condiția de inversabilitate poate fi formulată alternativ pentru  $[\Theta(L)]^{-1} y_t = \varepsilon_t$ .

Dacă avem  $y_t = \prod_{i=1}^q (1 - \lambda_i L) \varepsilon_t$ , unde  $\lambda_i$  sunt rădăcinile ecuației

$$P(\lambda) = \lambda^q + \theta_1 \lambda^{q-1} + \theta_2 \lambda^{q-2} + \dots + \theta_{q-1} \lambda + \theta_q = 0,$$

atunci condiția ca polinomul să fie inversabil, este ca  $|\lambda_i| < 1$  pentru toți  $i = 1, 2, \dots, q$ .

Exprimarea modelului MA ca un model AR( $\infty$ ) arată, în mod evident, că există o legătură directă între valoarea curentă a lui  $y_t$  și toate valorile sale anterioare.

Notăm că inversabilitatea nu are influență asupra staționarității unui proces. *Toate procesele de medie mobilă cu coeficienți finiți sunt staționare.* Dacă un proces ARMA este staționar sau nu, aceasta depinde numai de componenta AR a modelului.

**Un proces MA(q) cu coeficienți finiți este totdeauna staționar**, deoarece parametrii unui proces MA finit verifică totdeauna condițiile de staționaritate.

### Modele autoregresive (Auto Regressive - AR)

Modelele autoregresive sunt modele de regresie în care este explicată o variabilă prin trecutul său. Valoarea curentă  $y_t$  este exprimată ca o combinație liniară, finită, de valorile sale din trecut și un șoc aleator  $\varepsilon_t$ .

Seriile autoregresive prezintă o importanță deosebită din mai multe motive:

1. Aceste serii au o interpretare naturală – următoarea valoare observată este o perturbație a unei funcții simple a celor mai recente observații.
2. Parametrii acestor serii sunt ușor de estimat. În acest scop pot fi folosite pachetele de regresie standard.
3. Predicțiile pentru aceste serii sunt ușor de efectuat, folosindu-se pachetele de regresie standard.

### Modelul autoregresiv de ordinul unu, AR(1).

Cel mai simplu model autoregresiv, modelul AR(1), este de forma

$$y_t = \phi_1 y_{t-1} + \varepsilon_t, \quad t = 2, 3, \dots, n,$$

unde seria  $\{\varepsilon_t\}$  este zgomot alb cu media zero și varianța  $\sigma_\varepsilon^2$ . Acest model are forma unui model de regresie liniară simplă, în care  $y_t$  este variabila explicată iar  $y_{t-1}$  este variabila explicativă. Condiționat de  $y_{t-1}$ , avem:

$$E(y_t | y_{t-1}) = \phi_0 + \phi_1 y_{t-1} \text{ și } Var(y_t | y_{t-1}) = Var(\varepsilon_t) = \sigma_\varepsilon^2.$$

În descompunerea lui  $y_t$ , termenul întârziat  $\phi y_{t-1}$  este partea memorizată iar termenul  $\varepsilon_t$  este **inovația**. Este important de menționat că  $y_t$  depinde de tot trecutul său, dar memoria ansamblului trecutului este transmisă în totalitate prin observația precedentă  $y_{t-1}$ . Deoarece o observație nu depinde de trecut decât prin intermediul observației precedente, se poate arăta că, în acest model, toți coeficienții de autocorelație parțială de ordin  $k > 1$  sunt nuli.

După substituții succesive găsim că  $y_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots = \sum_{k=0}^{\infty} \phi^k \varepsilon_{t-k}$ . Această serie converge dacă

$|\phi| < 1$ , deoarece  $\sum |\phi|^{2k} < \infty$ . Limita seriei este staționară și satisface relația  $y_t = \phi y_{t-1} + \varepsilon_t$ . Astfel, dacă  $|\phi| < 1$ , atunci există o soluție staționară a ecuației  $y_t = \phi y_{t-1} + \varepsilon_t$ .

Reținem: Un proces AR(1) **este staționar** dacă  $|\phi| < 1$  și **nestaționar** dacă  $\phi = 1$ .

Folosim operatorul de întârziere  $L$  pentru a scrie **polinomul autoregresiv** al lui  $y_t$ :

$$\Phi(L) = (1 - \phi L).$$

Modelul AR(1) poate fi scris ca  $(1 - \phi L)y_t = \varepsilon_t$ .

Dacă  $|\phi| < 1$  și  $(1 - \phi L)$  este inversabil, procesul  $y_t$  se poate scrie sub forma:

$$y_t = (1 - \phi L)^{-1} \varepsilon_t = (1 + \phi L + \phi^2 L^2 + \dots) \varepsilon_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots = \sum_{k=0}^{\infty} \phi^k \varepsilon_{t-k}$$

Un proces AR(1) este totdeauna inversabil când parametrul modelului îndeplinește condiția  $|\phi| < 1$ . Spunem că rădăcina polinomului este  $1/\phi$  deoarece  $\Phi(z) = 0$  când  $z = 1/\phi$ .

Din reprezentarea lui  $y_t$  prin filtru liniar, se pot calcula momentele lui  $y_t$  folosind sumele infinite.

$$\text{Media este: } E(y_t) = \sum_{k=0}^{\infty} \phi^k E(\varepsilon_{t-k}) = 0,$$

$$\text{Varianța este } Var(y_t) = \sum_{k=0}^{\infty} \phi^{2k} Var(\varepsilon_{t-k}) = \frac{\sigma^2}{1 - \phi^2} \text{ dacă } |\phi| < 1.$$

Deci, dacă  $|\phi| < 1$ , media și varianța sunt **constante**, condiții necesare pentru staționaritate.

**Un proces AR(1) este staționar** dacă rădăcina polinomului autoregresiv  $\Phi(z) = (1 - \phi z)$  este mai mare decât 1, în modul. Această condiție este echivalentă cu condiția că rădăcina ecuației  $(\lambda - \phi) = 0$  este  $|\phi| < 1$ .

• **Funcția de Autocorelație** pentru un proces AR(1):

Înmulțim ambii membri ai relației  $y_t - \phi y_{t-1} = \varepsilon_t$  cu  $y_{t-k}$  și apoi aplicăm operatorul de medie.

$$y_t y_{t-k} - \phi y_{t-1} y_{t-k} = \varepsilon_t y_{t-k}$$

$$E(y_t y_{t-k}) - \phi E(y_{t-1} y_{t-k}) = E(\varepsilon_t y_{t-k})$$

$$\gamma_k - \phi \gamma_{k-1} = E(\varepsilon_t y_{t-k})$$

Pentru  $k = 0$  obținem:

$$E(\varepsilon_t y_t) = E(\varepsilon_t (\varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots)) = E(\varepsilon_t^2) = \sigma_\varepsilon^2.$$

Pentru  $k > 0$  obținem:

$$E(\varepsilon_t y_{t-k}) = E(\varepsilon_t (\varepsilon_{t-k} + \phi \varepsilon_{t-k-1} + \phi^2 \varepsilon_{t-k-2} + \dots)) = 0.$$

Rezultă că avem:

$$\gamma_0 - \phi \gamma_{-1} = \sigma_\varepsilon^2 = \gamma_0 - \phi \gamma_1$$

$$\gamma_k - \phi \gamma_{k-1} = 0 \text{ pentru } k = 1, 2, \dots$$

Pentru  $k = 1$  obținem  $\gamma_1 = \phi \gamma_0$  și înlocuim în penultima ecuație. Rezultă  $\gamma_0 = \sigma_\varepsilon^2 / (1 - \phi^2)$ .

Avem relația de recurență  $\gamma_k = \phi \gamma_{k-1}$ , iar prin împărțirea la  $\gamma_0$  rezultă că ACF este:

$$\rho_k = \phi \rho_{k-1} = \phi^2 \rho_{k-2} = \dots = \phi^k, \forall k \Rightarrow \text{ACF descrește geometric cu } k.$$

**Funcția de autocorelație a unui proces AR(1) slab staționar începe de la 1 și se diminuează în progresie geometrică, cu rata  $\phi$ . Valoarea lui  $y_t$  depinde de valorile din trecut și intensitatea acestei dependențe scade cu timpul. În consecință, un șoc într-un proces AR(1) afectează toate observațiile viitoare cu un efect descrescător. Coeficienții de autocorelație converg la zero dacă seria este staționară. Corelograma va arăta o descreștere exponențială cu valori pozitive dacă  $\phi$  este pozitiv și o descreștere sinusoidală (cu oscilații negativ-pozitiv) dacă  $\phi$  este negativ. Dacă  $\phi$  este pozitiv, valorile adiacente sunt pozitiv corelate, iar dacă**

$\phi$  este negativ, valorile adiacente sunt negativ corelate. Ambele descreșteri sunt lente dacă valoarea lui  $\phi$  este apropiată de 1 sau de -1. Cu cât este mai mare valoarea lui  $\phi$ , cu atât este mai puternică corelația din proces.

Observație: Situația  $|\phi| > 1$  (comportament exploziv) este considerată foarte rar în economie.

• **Funcția de Autocorelație parțială** pentru un proces AR(1)

Reamintim că PACF satisface

$$\phi_{11} = \rho_1 \text{ și } \phi_{22} = (\rho_2 - \rho_1^2)/(1 - \rho_1^2).$$

Aici avem:  $\phi_{11} = \phi$  și  $\phi_{22} = (\phi^2 - \phi^2)/(1 - \phi^2) = 0$ ,  $\phi_{kk} = 0$  pentru  $k > 1$ .

Pentru un model AR(1):

• **ACF scade treptat la zero**

• **PACF se anulează după lag-ul 1**




Fig.1. Funcțiile ACF și PACF pentru un proces AR(1)

**Modelul autoregresiv de ordinul 2, AR(2)**

Modelul AR(2) poate fi scris în mai multe moduri echivalente:

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

$$y_t - \phi_1 y_{t-1} - \phi_2 y_{t-2} = \varepsilon_t$$

$$(1 - \phi_1 L - \phi_2 L^2) y_t = \varepsilon_t$$

$\Phi(L)y_t = \varepsilon_t$ , unde  $\Phi(L) = (1 - \phi_1 L - \phi_2 L^2)$  este polinomul autoregresiv al procesului AR(2).

Cerințe:

- 1) Să se determine relația dintre parametrii modelului astfel încât procesul să fie staționar.
- 2) Să se calculeze media și varianța procesului AR(2).
- 3) Să se determine ACF și PACF pentru un proces AR(2).
- 4) Să se scrie și să se rezolve sistemul de ecuații Yule-Walker.

**Procesul AR(2) este staționar** iar polinomul  $\Phi(L) = (1 - \phi_1 L - \phi_2 L^2)$  este inversabil dacă rădăcinile ecuației

$\Phi(z) = (1 - \phi_1 z - \phi_2 z^2) = (1 - \lambda_1 z)(1 - \lambda_2 z) = 0$  se află în afara cercului unitate, adică  $|z_1| > 1$  și  $|z_2| > 1$  sau rădăcinile ecuației  $P(\lambda) = \lambda^2 - \phi_1 \lambda - \phi_2 = 0$  se află în interiorul cercului unitate, adică  $|\lambda_1| < 1$  și  $|\lambda_2| < 1$ .

Pentru ca ultimele două condiții să fie îndeplinite trebuie ca cei doi parametri ai modelului să satisfacă următoarele condiții:  $\phi_1 + \phi_2 < 1$ ,  $\phi_2 - \phi_1 < 1$  și  $|\phi_2| < 1$ .

Dacă rădăcinile ecuației caracteristice sunt reale, ele se obțin prin relațiile:  $\lambda_{1,2} = (\phi_1 \pm \sqrt{\phi_1^2 + 4\phi_2})/2$ .

Dacă rădăcinile ecuației caracteristice sunt numere complexe conjugate, ele se obțin prin relațiile:

$$\lambda_1 = a + bi, \lambda_2 = a - bi, a = \phi_1/2, b = (\sqrt{-\phi_1^2 - 4\phi_2})/2, \text{ deci } \lambda_{1,2} = (\phi_1 \pm i\sqrt{-\phi_1^2 - 4\phi_2})/2.$$

**Calcularea autocorelațiilor unui proces AR(2)**

Înmulțim ecuația  $y_t - \phi_1 y_{t-1} - \phi_2 y_{t-2} = \varepsilon_t$  prin  $y_{t-k}$ , după care aplicăm operatorul de medie și împărțim prin varianța  $\gamma_0$ , a lui  $y_t$ . Rezultă următoarele relații:

$$y_t y_{t-k} - \phi_1 y_{t-1} y_{t-k} - \phi_2 y_{t-2} y_{t-k} = \varepsilon_t y_{t-k}$$

$$E(y_t y_{t-k}) - \phi_1 E(y_{t-1} y_{t-k}) - \phi_2 E(y_{t-2} y_{t-k}) = E(\varepsilon_t y_{t-k})$$

$$\frac{E(y_t y_{t-k})}{\gamma_0} - \phi_1 \frac{E(y_{t-1} y_{t-k})}{\gamma_0} - \phi_2 \frac{E(y_{t-2} y_{t-k})}{\gamma_0} = \frac{E(\varepsilon_t y_{t-k})}{\gamma_0}.$$

Pentru  $k=0$  obținem:  $E(\varepsilon_t y_t) = \sigma^2$ . Avem  $\gamma_0 - \phi_1 \gamma_1 - \phi_2 \gamma_2 = \sigma^2 \Rightarrow \gamma_0(1 - \phi_1 \rho_1 - \phi_2 \rho_2) = \sigma^2$ .

Pentru  $k > 0$  obținem:  $E(\varepsilon_t y_{t-k}) = 0$ .

Deoarece  $E(\varepsilon_t y_{t-k}) = E(y_t) = 0$  pentru toți  $t$  și  $k > 0$ , obținem **ecuațiile Yule-Walker**:

$$\rho_k - \phi_1 \rho_{k-1} - \phi_2 \rho_{k-2} = 0 \text{ pentru } k > 0.$$

**Determinarea funcției ACF a unui model AR(2):**

$$k=1 \Rightarrow \rho_1 - \phi_1 \rho_0 - \phi_2 \rho_1 = 0 \Rightarrow \rho_1(1 - \phi_2) = \phi_1 \Rightarrow \rho_1 = \frac{\phi_1}{1 - \phi_2}$$

$$k=2 \Rightarrow \rho_2 - \phi_1 \rho_1 - \phi_2 \rho_0 = 0 \Rightarrow \rho_2 = \phi_1 \rho_1 + \phi_2 \Rightarrow \rho_2 = \frac{\phi_1^2}{1 - \phi_2} + \phi_2$$

$$k > 2 \Rightarrow \rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}.$$

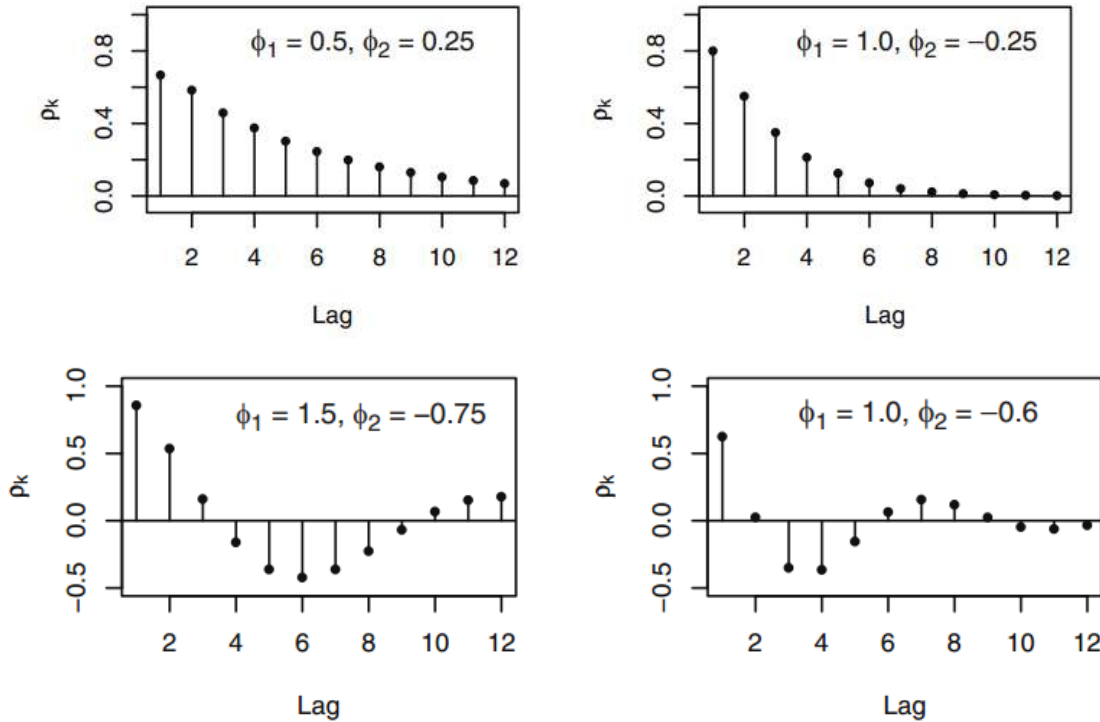


Fig. 2. ACF pentru modele AR(2)

Modul în care se comportă funcția ACF pentru diferite valori ale coeficienților  $\phi_1$  și  $\phi_2$ , ai modelului AR(2), poate fi studiat prin observarea soluției ecuației  $\gamma_k - \phi_1 \gamma_{k-1} - \phi_2 \gamma_{k-2} = 0$ , pentru  $k=1,2,\dots$ , adică  $\rho_k = A_1 \lambda_1^k + A_2 \lambda_2^k$ ,  $k=0,1,2,\dots$ , unde  $A_1$  și  $A_2$  sunt constante care se pot determina din condițiile inițiale  $\rho_0 = 1$  și  $\rho_{-1} = \rho_1$ .

Dacă rădăcinile  $\lambda_1$  și  $\lambda_2$  sunt egale, adică  $\lambda_1 = \lambda_2 = \lambda$ , atunci  $\rho_k = (A_1 + A_2 k) \lambda^k$ ,  $k=0,1,2,\dots$ . Aceste ecuații arată că ACF a unui model AR(2) va descrește exponențial când  $k \rightarrow \infty$ .

Dacă rădăcinile  $\lambda_1$  și  $\lambda_2$  sunt numere complexe conjugate, ACF va fi o funcție sinusoidală descrescătoare.

**Determinarea funcției PACF a unui model AR(2):**

Scriem ecuațiile Yule-Walker: 
$$\begin{cases} \rho_1 = \phi_1 + \rho_1 \phi_2 \\ \rho_2 = \rho_1 \phi_1 + \phi_2 \end{cases} \text{ sau sub forma } \begin{cases} \phi_1 + \rho_1 \phi_2 = \rho_1 \\ \rho_1 \phi_1 + \phi_2 = \rho_2 \end{cases}$$

Coefficienții de autocorelație parțială sunt:

$$\phi_{11} = \rho_1, \quad \phi_{22} = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2} \neq 0, \quad \phi_{kk} = 0 \text{ pentru } k > 2.$$

**Problemă:** Se consideră modelul  $y_t = 0,6 y_{t-1} - 0,08 y_{t-2} + \varepsilon_t$

Să se verifice dacă este îndeplinită condiția de staționaritate.

Avem  $\phi_1 = 0,6$  și  $\phi_2 = -0,08$

$$\Phi(L) = (1 - \phi_1 L - \phi_2 L^2) \Rightarrow \Phi(z) = (1 - \phi_1 z - \phi_2 z^2) = (1 - \lambda_1 z)(1 - \lambda_2 z) = 0$$

$$P(\lambda) = \lambda^2 - \phi_1 \lambda - \phi_2 = 0 \Rightarrow P(\lambda) = \lambda^2 - 0,6\lambda + 0,08 = 0$$

$$\Rightarrow \lambda_1 = 0,4 \text{ și } \lambda_2 = 0,2 \Rightarrow |\lambda_1| < 1 \text{ și } |\lambda_2| < 1.$$

Rezultă  $z_1 = 1/\lambda_1 = 1/0,4 = 2,5$  și  $z_2 = 1/\lambda_2 = 1/0,2 = 5$ , deci  $|z_1| > 1$  și  $|z_2| > 1$ .

Condiția de staționaritate este îndeplinită.

**Problemă:** Se consideră modelul  $y_t = 1,5 y_{t-1} - 0,75 y_{t-2} + \varepsilon_t$

a) Verificați dacă este îndeplinită condiția de staționaritate.

b) Calculați ACF și reprezentați corelograma asociată.

c) Calculați PACF și reprezentați corelograma corespunzătoare.

a) Avem  $\phi_1 = 1,5$  și  $\phi_2 = -0,75$

$$\Phi(L) = (1 - \phi_1 L - \phi_2 L^2) \Rightarrow \Phi(z) = (1 - \phi_1 z - \phi_2 z^2) = (1 - \lambda_1 z)(1 - \lambda_2 z) = 0$$

$$P(\lambda) = \lambda^2 - \phi_1 \lambda - \phi_2 = 0 \Rightarrow P(\lambda) = \lambda^2 - 1,5\lambda + 0,75 = 0 \Rightarrow$$

$$\lambda_1 = a + bi = 0,75 + 0,43i \text{ și } \lambda_2 = a - bi = 0,75 - 0,43i \Rightarrow |\lambda| = R = \sqrt{a^2 + b^2} = 0,8645$$

Condiția de staționaritate este îndeplinită.

b) ACF:  $\rho_1 = 0,8571$ ;  $\rho_2 = 0,5357$ ;  $\rho_3 = 0,1607$ ;  $\rho_4 = -0,1607$ ;  $\rho_5 = -0,3616$

c) PACF:  $\phi_{11} = \rho_1 = 0,8571$ ;  $\phi_{22} = -0,75$ ;  $\phi_{kk} = 0$  pentru  $k > 2$

### **Modelul autoregresiv de ordinul p, AR(p)**

Un proces stochastic cu valori reale  $y_t$  se spune că este un proces autoregresiv de ordinul  $p$  și se notează prin AR(p) dacă există  $\phi_1, \phi_2, \dots, \phi_p \in \mathbb{R}$ , cu  $\phi_p \neq 0$  și un proces al erorilor zgomot alb  $\varepsilon_t$ , astfel încât

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad t \in \mathbb{Z}.$$

Observăm că valoarea unui proces AR(p) la momentul  $t$  este regresată în raport cu  $p$  valori ale sale din trecut plus un șoc aleator.

Folosind operatorul lag  $\Phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p$  această relație se poate scrie sub forma

$$\Phi(L)y_t = y_t - \phi_1 y_{t-1} - \phi_2 y_{t-2} - \dots - \phi_p y_{t-p} = \varepsilon_t \text{ sau } \Phi(L)y_t = \varepsilon_t.$$

Modelul  $\Phi(L)y_t = \varepsilon_t$  conține  $p + 2$  parametri necunoscuți  $\mu_y, \phi_1, \phi_2, \dots, \phi_p, \sigma_\varepsilon^2$ , care în practică vor fi estimați din date. Se definește polinomul caracteristic atașat unui proces AR(p) prin relația:

$$P(z) = z^p - \phi_1 z^{p-1} - \phi_2 z^{p-2} - \dots - \phi_p.$$

Între polinomul caracteristic al procesului și polinomul lag autoregresiv utilizat pentru definirea procesului există relația:  $P(z) = z^p \Phi(1/z)$ .

În general, **polinomul autoregresiv**  $\Phi(L)$  este **inversabil** dacă toate rădăcinile  $z$ , ale ecuației

$\Phi(z) = 1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p = 0$  sunt mai mari decât unu în valoare absolută. Comparând cu polinomul

$P(\lambda) = (\lambda^p - \phi_1 \lambda^{p-1} - \phi_2 \lambda^{p-2} - \dots - \phi_p) = 0$  este logic că toate rădăcinile  $z$  ar trebui să se găsească în afara cercului

unitate deoarece ele sunt inversele valorilor proprii corespunzătoare  $\lambda$ , sau  $z = 1/\lambda$ .

În timp ce un proces MA(q) este în mod automat staționar, un proces AR(p) nu este.



**Teoremă (Condiția de staționaritate):** Ecuația  $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$  are o soluție staționară dacă toate rădăcinile ecuației  $\Phi(z) = 1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p = 0$  sunt în afara cercului unitate.

**Observație.** Dacă  $z$  este rădăcina a ecuației  $\Phi(z) = 1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p = 0$ , unde puterile crescătoare ale lui  $z$  sunt asociate cu indici crescători ai coeficienților, atunci  $\lambda = 1/z$  este o rădăcină a ecuației  $P(\lambda) = \lambda^p - \phi_1 \lambda^{p-1} - \phi_2 \lambda^{p-2} - \dots - \phi_p = 0$ .

**Calcularea autocorelațiilor unui proces AR(p) . Ecuațiile Yule-Walker**

$$\begin{cases} \rho_1 = \phi_1 + \rho_1 \phi_2 + \dots + \rho_{p-1} \phi_p \\ \rho_2 = \rho_1 \phi_1 + \phi_2 + \dots + \rho_{p-2} \phi_p \\ \vdots \\ \rho_p = \rho_{p-1} \phi_1 + \rho_{p-2} \phi_2 + \dots + \phi_p \end{cases}$$

Funcțiile ACF și PACF pot fi obținute rezolvând sistemul de **ecuații Yule-Walker**. Aceste ecuații exprimă coeficienții de autocorelație  $\rho_k$  sub forma unor funcții de coeficienții autoregresivi  $\phi_i$ .

Definim matricea coeficienților liniari de autocorelație prin  $R(p)$ , vectorul parametrilor modelului prin  $\phi$  și vectorul coeficienților de autocorelație prin  $\rho$ . Sistemul de ecuații Yule-Walker poate fi scris în formă matriceală ca  $R(p) \cdot \phi = \rho$ . Această ecuație matriceală oferă un estimator al coeficienților  $\phi_1, \phi_2, \dots, \phi_p$ , înlocuind autocorelațiile  $\rho_k$  prin valorile empirice  $\hat{\rho}_k$ , corespunzătoare.

Dacă matricea  $R(p)$  este inversabilă, parametrii  $\phi_1, \phi_2, \dots, \phi_p$ , ai modelului, vor fi estimați prin relația:  $\phi = R^{-1}(p) \cdot \rho$ . Se observă că parametrii modelului pot fi estimați în funcție de primii  $p$  coeficienți de autocorelație. Componenta  $k$  din vectorul  $\phi$ , al parametrilor modelului, este notată prin  $\phi_{kk}$  și reprezintă coeficientul de autocorelație parțială de ordinul  $k$ .

Se poate afla coeficientul  $\phi_{kk}$  aplicând regula lui Cramer:

$$\phi_{kk} = \rho_{kk} = \frac{|R^*(p)|}{|R(p)|}, \quad R^*(p) \text{ fiind matricea } R(p) \text{ cu ultima coloană înlocuită prin vectorul } \rho.$$

Din definiția lui  $\phi_{kk}$  rezultă funcțiile de autocorelație parțială ale proceselor AR.

PACF a procesului AR(1) este:  $\phi_{11} = \rho_1 = \phi$  și  $\phi_{kk} = 0$  pentru  $k > 1$ .

PACF a procesului AR(2) este:  $\phi_{11} = \rho_1$ ,  $\phi_{22} = (\rho_2 - \rho_1^2)/(1 - \rho_1^2) \neq 0$  și  $\phi_{kk} = 0$  pentru  $k > 2$ .

PACF a procesului AR(p) este:  $\phi_{11} = \rho_1$ ,  $\phi_{22} \neq 0$ , ...,  $\phi_{pp} \neq 0$  și  $\phi_{kk} = 0$  pentru  $k > p$ .

Coeficienții de autocorelație parțială, de ordin mai mare decât ordinul procesului autoregresiv în cauză, sunt zero, deoarece nu există o corelație directă între  $y_t$  și  $y_{t-k}$  pentru  $k > p$ . Aceasta este o caracteristică foarte utilă a PACF, care poate ajuta în procesul de identificare a ordinului  $p$ , al unui model AR(p). Folosim faptul că  $\hat{\phi}_{pp} \approx \phi_{pp} \neq 0$ , în timp ce pentru  $k > p$ , ar trebui să aibă valori foarte apropiate de zero adică  $\hat{\phi}_{kk} \approx \phi_{kk} = 0$ .

Reținem că un proces autoregresiv poate fi descris prin două funcții:

**i) o funcție ACF infinită**, reprezentată sau printr-o combinație de exponențiale sau de funcții sinusoidale, care descresc la zero. ACF descrește la zero exponențial când rădăcinile polinomului  $\Phi(L) = 0$  sunt reale și descrește cu fluctuații sinusoidale când acestea sunt complexe.

**ii) o funcție PACF** care ia valoarea zero pentru lag-uri mai mari decât ordinul procesului, adică  $\phi_{kk} = 0, \forall k > p$ .

**PACF pentru un proces de medie mobilă** Pentru procesele MA funcțiile PACF au expresii complicate.

Se poate observa că ACF pentru un model AR are aceeași formă cu PACF pentru un model MA și că ACF pentru un model MA are aceeași formă cu PACF pentru un model AR.

Pentru un proces AR(p) avem ACF infinită, în timp ce PACF devine zero după lag-ul  $p$ . Pentru un proces MA(q), ACF devine zero după lag-ul  $q$ , în timp ce PACF descrește asimptotic către zero.

**Modele autoregresive de medie mobilă (Auto Regressive Moving Average - ARMA(p,q))**

Un model de tip ARMA(p,q) are o componentă de tip autoregresiv și o componentă de tip medie mobilă. Componenta autoregresivă se justifică prin faptul că variabilele economice au în evoluție un puternic caracter inerțial iar componenta de medie mobilă este efectul unor evenimente neașteptate, nepredictibile, asupra unei variabile economice.

Modelul ARMA este cel mai indicat model pentru a se realiza predicții în economie.

Fie procesul  $\varepsilon_t$  zgomot alb,  $p, q \geq 0$  numere întregi și coeficienții  $\phi_1, \phi_2, \dots, \phi_p, \theta_1, \theta_2, \dots, \theta_q \in \mathbb{R}$ .

Un proces stochastic  $Y_t$  cu valori reale este un proces autoregresiv de medie mobilă de ordin p,q și se notează ARMA(p,q) dacă satisface o ecuație de forma:

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}.$$

Putem rescrie această ecuație folosind operatorul lag, polinomul autoregresiv de ordin p și polinomul de medie mobilă de ordin q:

$$\Phi(L)y_t = \Theta(L)\varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma_\varepsilon^2)$$

Modelul este staționar dacă componenta AR este staționară, adică rădăcinile ecuației  $\Phi(z)=0$  sunt în afara cercului unitate. Pentru un model ARMA(p,q) avem condiția necesară  $\sum_{i=1}^p \phi_i < 1$ .

Modelul ARMA este inversabil dacă componenta MA este inversabilă, adică rădăcinile ecuației  $\Theta(z)=0$  sunt în afara cercului unitate. Caracteristicile unui proces ARMA vor fi o combinație a celor de la componentele AR și MA.

ACF descrește la zero când decalajul tinde la infinit, scăzând exponențial când rădăcinile ecuației  $\Phi(z)=0$  sunt reale și cu fluctuații când acestea sunt complexe; PACF descrește la zero, exponențial când rădăcinile ecuației  $\Theta(z)=0$  sunt reale și cu fluctuații când acestea sunt complexe. Obținerea celor două funcții necesită calcule algebrice complicate.

Funcția ACF (singură), poate face distincția dintre un proces AR pur și un proces MA pur.

Funcția PACF este utilă pentru a distinge un proces AR(p) de un proces ARMA(p,q). Astfel, un proces AR(p) are o ACF descrescătoare geometric și o PACF care se anulează după p laguri, în timp ce un proces ARMA(p,q) are ambele funcții ACF și PACF descrescătoare geometric.

Clasa de procese ARMA este folosită pentru a modela procese stochastice staționare.

### **Modele ARMA(1,1)**

Fie  $\{y_t\}$  un proces stochastic de tip ARMA(1,1).  $y_t = \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$

a) Să se scrie modelul cu ajutorul operatorului de decalaj L.  $y_t - \phi y_{t-1} = \varepsilon_t + \theta \varepsilon_{t-1} \Rightarrow (1 - \phi L)y_t = (1 + \theta L)\varepsilon_t$

b) Să se determine autocovarianțele procesului, apoi să se determine autocorelațiile procesului.

Am obținut exprimarea cu ajutorul filtrului liniar:  $y_t = \varepsilon_t + (\phi + \theta)\varepsilon_{t-1} + \phi(\phi + \theta)\varepsilon_{t-2} + \phi^2(\phi + \theta)\varepsilon_{t-3} + \dots$

Obținem:  $E(\varepsilon_t y_t) = E(\varepsilon_t (\varepsilon_t + (\phi + \theta)\varepsilon_{t-1} + \phi(\phi + \theta)\varepsilon_{t-2} + \phi^2(\phi + \theta)\varepsilon_{t-3} + \dots)) = \sigma^2$

$$E(\varepsilon_{t-1} y_t) = E(\varepsilon_{t-1} (\varepsilon_t + (\phi + \theta)\varepsilon_{t-1} + \phi(\phi + \theta)\varepsilon_{t-2} + \phi^2(\phi + \theta)\varepsilon_{t-3} + \dots)) = (\phi + \theta)\sigma^2$$

$$y_{t-1} = \varepsilon_{t-1} + (\phi + \theta)\varepsilon_{t-2} + \phi(\phi + \theta)\varepsilon_{t-3} + \phi^2(\phi + \theta)\varepsilon_{t-4} + \dots$$

$$E(\varepsilon_t y_{t-1}) = E(\varepsilon_t (\varepsilon_{t-1} + (\phi + \theta)\varepsilon_{t-2} + \phi(\phi + \theta)\varepsilon_{t-3} + \phi^2(\phi + \theta)\varepsilon_{t-4} + \dots)) = 0$$

$$E(\varepsilon_{t-1} y_{t-1}) = E(\varepsilon_{t-1} (\varepsilon_{t-1} + (\phi + \theta)\varepsilon_{t-2} + \phi(\phi + \theta)\varepsilon_{t-3} + \phi^2(\phi + \theta)\varepsilon_{t-4} + \dots)) = \sigma^2 \Rightarrow E(\varepsilon_{t-1} y_{t-2}) = 0$$

Relația  $y_t - \phi y_{t-1} = \varepsilon_t + \theta \varepsilon_{t-1}$  o înmulțim cu  $y_{t-k} \Rightarrow y_t y_{t-k} - \phi y_{t-1} y_{t-k} = \varepsilon_t y_{t-k} + \theta \varepsilon_{t-1} y_{t-k}$

Aplicăm operatorul de medie:

$$E(y_t y_{t-k}) - \phi E(y_{t-1} y_{t-k}) = E(\varepsilon_t y_{t-k}) + \theta E(\varepsilon_{t-1} y_{t-k})$$

$$\gamma_k - \phi \gamma_{k-1} = E(\varepsilon_t y_{t-k}) + \theta E(\varepsilon_{t-1} y_{t-k})$$

Pentru k=0 obținem:  $\gamma_0 - \phi \gamma_1 = E(\varepsilon_t y_t) + \theta E(\varepsilon_{t-1} y_t)$

$$\gamma_0 - \phi \gamma_1 = \sigma^2 + \theta(\phi + \theta)\sigma^2 = (1 + \theta(\phi + \theta))\sigma^2$$

Pentru k=1 obținem:

$$\gamma_1 - \phi \gamma_0 = E(\varepsilon_t y_{t-1}) + \theta E(\varepsilon_{t-1} y_{t-1})$$

$$\gamma_1 - \phi \gamma_0 = 0 + \theta \sigma^2 \Rightarrow \gamma_1 = \phi \gamma_0 + \theta \sigma^2$$

Înlocuim în ecuația obținută pentru  $k=0$  și obținem:

$$\gamma_0 - \phi(\phi \gamma_0 + \theta \sigma^2) = (1 + \theta(\phi + \theta))\sigma^2$$

$$(1 - \phi^2)\gamma_0 = (1 + \phi\theta + \theta(\phi + \theta))\sigma^2 = (1 + 2\phi\theta + \theta^2)\sigma^2 \Rightarrow \gamma_0 = \frac{1 + 2\phi\theta + \theta^2}{1 - \phi^2}\sigma^2$$

$$\text{Dar } \gamma_1 = \phi \gamma_0 + \theta \sigma^2 = \frac{\phi + 2\phi^2\theta + \phi\theta^2 + \theta - \phi^2\theta}{1 - \phi^2}\sigma^2$$

$$\gamma_1 = \frac{\phi + \theta + \phi^2\theta + \phi\theta^2}{1 - \phi^2}\sigma^2 = \frac{(\phi + \theta)(1 + \phi\theta)}{1 - \phi^2}\sigma^2$$

$$\text{Pentru } k=2 \text{ obținem: } \gamma_2 - \phi \gamma_1 = E(\varepsilon_t y_{t-2}) + \theta E(\varepsilon_{t-1} y_{t-2}) = 0$$

$$\text{Pentru } k \geq 2 \text{ avem } \gamma_k = \phi \gamma_{k-1}$$

$$\text{Determinăm ACF } \rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(\phi + \theta)(1 + \phi\theta)}{1 + 2\phi\theta + \theta^2}$$

Pentru  $k \geq 2$  avem  $\rho_k = \phi \rho_{k-1}$ . Mărima lui  $\rho_1$  depinde atât de  $\phi$  cât și de  $\theta$ .

Dacă  $0 < \phi < 1$ , convergența este directă. Dacă  $-1 < \phi < 0$ , autocorelațiile vor oscila.

Funcția ACF a unui model ARMA(1,1) este similară cu cea a unui proces AR(1), fiind o descreștere exponențială.

Diferența este că descreșterea începe de la  $\rho_1$  și nu de la  $\rho_0 = 1$  ca în cazul AR(1).

Funcția PACF pentru un model ARMA(1,1) se comportă ca în cazul MA(1), după valoarea inițială  $\phi_{11} = \rho_1$  urmează o descreștere exponențială.

$$\phi_{22} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}, \phi_{kk} = \frac{\rho_k - \sum_{j=1}^{k-1} \phi_{k-1,j} \rho_{k-j}}{1 - \sum_{j=1}^{k-1} \phi_{k-1,j} \rho_j}, \text{ unde } \phi_{kj} = \phi_{k-1,j} - \phi_{kk} \phi_{k-1,k-j}, j = 1, 2, 3, \dots, k-1.$$

$$\text{Exemplu: } y_t = \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$$

$$y_t = -0,7 y_{t-1} + \varepsilon_t - 0,7 \varepsilon_{t-1} \Rightarrow \phi = -0,7 \text{ și } \theta = -0,7$$

a) Să se calculeze ACF:

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(\phi + \theta)(1 + \phi\theta)}{1 + 2\phi\theta + \theta^2} \Rightarrow \rho_1 = \frac{(-0,7 - 0,7\theta)(1 + 0,49)}{1 + 2(0,49) + 0,49} = -0,8445$$

$$\text{Pentru } k \geq 2 \text{ avem } \rho_k = \phi \rho_{k-1}$$

$$\rho_2 = \phi \rho_1 = (-0,7)(-0,8445) = 0,591$$

$$\rho_3 = \phi \rho_2 = -0,414; \rho_4 = 0,290; \rho_5 = -0,203; \rho_6 = 0,142; \rho_7 = -0,099; \rho_8 = 0,07$$

b) Să se calculeze PACF:

$$\phi_{11} = \rho_1 = -0,8445$$

$$\phi_{22} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2} = \frac{0,591 - (-0,8445)^2}{1 - (-0,8445)^2} = -0,426$$

$$\text{Pentru a determina } \phi_{33}, \text{ calculăm } \phi_{21} = \phi_{11} - \phi_{22}\phi_{11} = -1,204$$

$$\phi_{33} = \frac{\rho_3 - \sum_{j=1}^2 \phi_{2j} \rho_{3-j}}{1 - \sum_{j=1}^2 \phi_{2j} \rho_j} = \frac{(-0,414) - (-1,204)(0,591) - (-0,426)(-0,8445)}{1 - (-1,204)(-0,8445) - (-0,426)(0,591)} = -0,262$$

$$\phi_{44} = \frac{\rho_4 - \sum_{j=1}^3 \phi_{3j} \rho_{4-j}}{1 - \sum_{j=1}^3 \phi_{3j} \rho_j} = -0,173$$

$$\text{unde } \phi_{3j} = \phi_{2j} - \phi_{33}\phi_{2,2-j} \Rightarrow \phi_{31} = -1,315; \phi_{32} = -0,74;$$

$$\phi_{55} = -0,117; \phi_{66} = -0,081; \phi_{77} = -0,056; \phi_{88} = -0,039$$