

### **2.3. Modele ARIMA și construirea lor prin metodologia BOX-JENKINS**

1. Cum modelăm o serie staționară, adică, ce fel de model de regresie putem folosi pentru a descrie comportamentul unei serii staționare?
2. Cum folosim modelul ajustat pentru prognoză?

Modelele de tip ARMA pot să aproximeze cele mai multe procese staționare.

Pentru că în economie sunt puține serii de timp staționare, sunt necesare modele care să fie capabile să reproducă comportamentul nestaționar. Astfel de modele sunt modelele de tip ARIMA (modele autoregresive integrate de medie mobilă), care se obțin prin presupunerea că o serie cronologică poate fi reprezentată, după diferențiere, printr-un model de tip ARMA.

Multe serii de timp din economie sunt nestaționare, dar sunt integrate. Dacă o serie de timp este  $I(d)$ , după diferențierea seriei de  $d$  ori se obține o serie staționară, adică  $I(0)$ . Aplicând un model ARMA acestei serii  $I(0)$ , spunem că seria de timp originală este un proces de medie mobilă integrat, autoregresiv, notat  $ARIMA(p,d,q)$ . Se știe deja că  $p$  indică numărul de termeni autoregresivi,  $q$  indică numărul de termeni de medie mobilă, iar  $d$  arată de câte ori a fost diferențiată seria pentru a deveni staționară.

Metodologia Box-Jenkins are ca obiectiv identificarea și estimarea unui model statistic care poate fi considerat că a generat datele de selecție. Acest model estimat va fi utilizat pentru prognoze și este necesară presupunerea că are caracteristici constante în timp. Selectarea modelului ARIMA potrivit pentru datele observate se realizează printr-o procedură iterativă (metodologia Box-Jenkins), bazată pe mai multe etape.

#### **Etapa I. Identificarea.**

Obiectivul identificării este de a selecta o subclasă a unei familii de modele ARIMA, potrivite pentru a reprezenta o serie de timp, adică un proces economic evolutiv.

În etapa de identificare sunt analizate datele observate și toate informațiile disponibile care sunt capabile să sugereze o subclasă de modele ce pot descrie modul de generare a datelor.

Elementele de teorie economică pot sugera tipul de model potrivit pentru un anumit proces economic. Astfel, **procesele economice inerțiale (consumul, inflația, plata impozitelor)** sau cele dependente de propriile realizări anterioare (**exportul, productivitatea, investițiile, producția din sectorul zootehnic, calitatea producției**), se recomandă a fi reprezentate de un model AR, ARI, ARMA sau ARIMA.

**Procesele economice care pot fi relativ ușor influențate de șocuri exterioare**, dar care permit măsuri compensatorii în timp (**aprovizionarea, producția, cotația la bursă**) se recomandă a fi reprezentate de un model MA sau care include o parte MA.

Identificarea înseamnă determinarea tipului de model și a ordinului modelului ce urmează a fi folosit pentru a reproduce caracteristicile dinamice ale datelor. Pentru a determina cea mai bună specificare sunt folosite reprezentări grafice ale datelor și ale funcțiilor ACF și PACF. Se analizează funcțiile de autocorelație și autocorelație parțială.

Mai întâi se examinează seria de analizat, pentru a vedea dacă ar fi putut fi generată de un proces staționar. De regulă, seriile de timp din economie nu sunt staționare. O astfel de serie poate avea următoarele caracteristici:

1. Seria prezintă o medie care nu este constantă în timp, dar variațiile sunt constante de la o perioadă la alta; urmează, de regulă, o traiectorie liniară, cu panta pozitivă sau negativă. Se spune că este o serie nestaționară de tip omogen.
2. Seria prezintă variații care nu sunt constante de la o perioadă la alta. Se spune că este o serie nestaționară de tip neomogen.

Folosim reprezentarea grafică a seriei pentru a vedea dacă are varianță staționară. Dacă dispersia datelor variază cu timpul, seria este nestaționară. În acest caz se poate aplica datelor transformarea Box-Cox.

Urmează analiza staționarității în medie. Acest lucru se poate face examinând graficul valorilor seriei, corelogramele de selecție sau prin aplicarea unui test pentru o rădăcină egală cu 1, precum testul Dickey-Fuller. Autocorelațiile de selecție sunt estimații consistente ale coeficienților populației corespunzători, așa încât corelograma de selecție a unui proces staționar tinde la zero pentru lungimi de lag moderate. O serie nestaționară are o ACF care nu descrește. O serie integrată are SACF ce descrește foarte încet, iar SPACF scade foarte repede, la lagul  $k = 2$  și prima valoare este foarte apropiată de 1.

Dacă seria arată un model de nestaționaritate, se staționarizează seria prin aplicarea unor transformări potrivite. De exemplu, se logaritmează valorile inițiale ale seriei, apoi se diferențiază seria până la obținerea staționarității. Luăm seria diferențelor de ordinul întâi și analizăm dacă este staționară într-un mod similar. Metodele grafice pot fi însoțite de teste de rădăcină unitară. Acest proces de efectuare a diferențelor va continua până la obținerea unei serii staționare,  $z_t$ .

După obținerea unei serii staționare  $z_t$ , se compară SACF și SPACF ale lui  $z_t$  cu diferite modele teoretice ARMA, iar această comparație poate sugera câteva modele plauzibile.

**În cazul unui model AR(p)** ACF este infinită iar PACF este finită.

Coeficienții de autocorelație descresc spre 0 geometric sau în alternanță, pe măsură ce crește lagul  $k$ .

Coeficienții de autocorelație parțială descresc brusc la 0 după un anumit număr de decalaje, astfel încât pentru  $k > p$ ,  $\phi_{kk} \approx 0$ .

**Rezultă că, dacă coeficienții  $\hat{\rho}_k$  scad în progresie geometrică și coeficienții  $\hat{\phi}_{kk}$  scad brusc astfel încât  $\hat{\phi}_{k,k} \approx 0$ , pentru  $k > p$ , se recomandă un model AR(p). Deci  $p$  este cea mai mare valoare a lui  $k$ , pentru care coeficienții de autocorelație parțială estimați,  $\hat{\phi}_{kk}$ , se află în afara intervalului  $(\pm 1,96/\sqrt{n})$ .**

**În cazul unui model MA(q)**, PACF este infinită iar ACF este finită.

Coeficienții de autocorelație scad brusc la 0 astfel încât pentru  $k > q$ ,  $\rho_k \approx 0$ .

Coeficienții de autocorelație parțială descresc spre 0 exponențial sau cu fluctuații.

**Rezultă că, dacă coeficienții  $\hat{\rho}_k$  scad brusc astfel încât  $\hat{\rho}_k \approx 0$  pentru  $k > q$  și coeficienții  $\hat{\phi}_{kk}$  scad în progresie geometrică, se recomandă un model MA(q). Deci  $q$  este cea mai mare valoare a lui  $k$ , pentru care coeficienții de autocorelație estimați,  $\hat{\rho}_k$ , se află în afara intervalului  $(\pm 1,96/\sqrt{n})$ .**

**Pentru un model ARMA(p,q)**, atât coeficienții de autocorelație cât și coeficienții de autocorelație parțială descresc spre 0 exponențial sau geometric. Ordinul  $p$ , al părții autoregresive din model, este dat de coeficientul de autocorelație parțială care prezintă un nivel semnificativ, iar ordinul  $q$ , al părții de medie mobilă din model, este dat de coeficientul de autocorelație care prezintă un nivel semnificativ. La acest moment, folosirea unui model de tip ARMA(p,q) este doar la stadiul de intenție.

**Observație:** Scăderea coeficienților de autocorelație trebuie înțeleasă în valoare absolută.

Descrșterea coeficienților de AC sau PAC poate fi întreruptă de valori mai mari (în valoare absolută) în cazul în care datele prezintă sezonabilitate (de ex., în cazul datelor trimestriale, se pot întâlni valori mari ale coeficienților  $\hat{\rho}_4$  sau  $\hat{\phi}_{44}$ , comparativ cu valorile coeficienților  $\hat{\rho}_3$ ,  $\hat{\rho}_5$ ,  $\hat{\rho}_6$ .

Se recomandă selectarea mai multor variante de modele, printre care și o variantă ARMA, pentru a fi estimate și verificate.

- Dacă există o valoare a decalajului,  $q$ , după care valoarea funcției de autocorelație scade brusc spre 0 rezultă că, pentru prelucrarea seriei, este indicată folosirea unui proces MA( $q$ ) pur sau a unui proces ce conține o componentă MA( $q$ ).

- Dacă valoarea funcției de autocorelație parțială  $\hat{\rho}_{kk} = \hat{\phi}_{kk}$ , scade brusc spre 0 după o valoare a decalajului egală cu  $p$ , rezultă că, pentru prelucrarea seriei, este indicată folosirea unui proces AR( $p$ ) pur sau a unui proces ce conține o componentă AR( $p$ ). Se consideră că valoarea lui  $\hat{\rho}_{kk} = \hat{\phi}_{kk}$  diferă semnificativ față de zero dacă nu este conținută în intervalul

$$\left( -t_{\frac{\alpha}{2}; n-2} \cdot \frac{1}{\sqrt{n}}, +t_{\frac{\alpha}{2}; n-2} \cdot \frac{1}{\sqrt{n}} \right).$$

## **Etapa II. Estimarea parametrilor modelului identificat.**

Estimarea parametrilor unui model de tip AR( $p$ ) se face prin MCMMP, minimizând suma pătratelor reziduurilor sau prin ecuațiile Yule-Walker de selecție.

Dacă în model există termeni de tip MA, minimizarea sumei pătratelor reziduurilor sau maximizarea funcției de verosimilitate necesită metode de estimare neliniare (Newton, Davidson-Fletcher-Powell).

Parametrii unui model ARIMA( $p, d, q$ ), se pot estima consistent prin MCMMP sau prin metoda verosimilității maxime. Ambele procedee de estimare sunt bazate pe calculul inovațiilor  $\varepsilon_t$  din valorile variabilei staționare.

Estimarea diverselor variante de modele, care au fost sugerate de corelogramă în etapa de identificare, va fi realizată cu ajutorul unui program ARMA dintr-un pachet de programe (EViews, SAS, SPSS). Vom atribui valori pentru  $p$  și  $q$  în diverse combinații și vom obține estimări ale coeficienților modelelor corespunzătoare.

## **Verificarea corectitudinii modelului identificat.**

După ce modelele ARMA selectate au fost estimate, dorim să ne asigurăm că sunt potrivite. Pentru aceasta se analizează atât reziduurile cât și parametrii pentru fiecare model.

### **Testarea reziduurilor**

Practica standard este de a reprezenta grafic reziduurile modelului estimat.

Dacă modelul estimat este adecvat, reziduurile ar trebui să fie aproximativ zgomot alb. Deci, reziduurile obținute pentru modelul estimat sunt analizate pentru a stabili dacă provin dintr-un proces de zgomot alb. În caz afirmativ, tipul de model propus este o bună aproximație pentru procesul stochastic de bază. În caz contrar, procesul este reluat, metoda fiind una iterativă.

Pentru a controla dacă reziduurile au media zero și sunt necorelate folosim atât graficul, cât și ACF și PACF ale reziduurilor. ACF și PACF teoretice ale procesului WN iau valoarea zero pentru lagurile  $k \neq 0$ , așa că, dacă modelul este potrivit, cei mai mulți din coeficienții funcțiilor SACF și SPACF ar trebui să fie apropiați de zero. În practică, cerem ca 95% din acești coeficienți să se afle în interiorul unor limite de nesemnificație. Mai mult, statistica Ljung-Box ar trebui să aibe valori mici, deoarece corespunde la variabile necorelate.

Un model care conduce la obținerea unor coeficienți de autocorelație a reziduurilor semnificativi sau la o statistică Q semnificativă la nivelul de semnificație de 10%, trebuie eliminat.

Dacă se observă că varianța reziduurilor este crescătoare, rezultă că este potrivită o transformare logaritmică. Este foarte important ca reziduurile obținute prin estimarea unui model să fie serial necorelate. Deci, orice model care nu produce reziduuri aleatoare ar trebui să nu fie luat în considerare, ci eliminat.

### **Testarea parametrilor**

Se pot aplica testele de semnificație clasice  $t$  și  $F$

Este important, de asemenea, să fie satisfăcute condițiile de staționaritate și inversabilitate. Dacă factorizăm polinoamele AR și MA și una din aceste rădăcini este apropiată de 1, aceasta este un semn de LACK a staționarității sau inversabilității.

### Departajarea între mai multe modele

Presupunând că sunt estimați parametrii pentru mai multe modele identificate ca fiind  $ARIMA(p_i, d, q_i)$ , se pot utiliza două tipuri de indicatori: ai calității reziduului sau ai teoriei informației.

a) Indicatori ai calității reziduului

Dintre modele estimate se alege modelul cu cea mai mică varianță a reziduurilor, cu cea mai mare valoare a lui  $R^2$  și cu cea mai mare valoare a statisticii F.

b) Indicatori ai teoriei informației

Pentru fiecare din modelele estimate se calculează indicatorii AIC(criteriul Akaike) și BIC (criteriul Schwarz sau bayesian):  $AIC = \log \hat{\sigma}_\varepsilon^2 + 2 \frac{p+q}{n}$ ,  $BIC = \log \hat{\sigma}_\varepsilon^2 + (p+q) \frac{\log n}{n}$ .

Se alege modelul cu cea mai mică valoare a indicatorului.

### Etapa III. Efectuarea de prognoze cu ajutorul modelelor ARIMA.

Obiectivul principal urmărit prin construirea unui model ARMA este de a predicta sau prognoza evoluția viitoare a unei variabile economice. Modelul selectat, pentru care s-a verificat corectitudinea, poate fi utilizat pentru prognoză. Modelele ARIMA sunt destul de apreciate pentru succesul în a face predicții. Prognozele obținute prin aceste modele sunt considerate mai bune, mai ales pe termen scurt, decât cele obținute prin modelarea econometrică tradițională, aplicată în cazul seriilor cronologice.

Prognozarea unei serii de timp constă în încercarea de a previziona valori viitoare ale seriei, ținând seama de valorile din trecut ale seriei și de valorile din trecut ale unui termen eroare. Se pot efectua **prognoze punctuale** (se previzionează o singură valoare a variabilei) sau **prognoze pe interval** (se determină un domeniu de valori în care anticipăm că se va afla valoarea viitoare a variabilei, pentru un nivel de semnificație dat).

Ipoteza cheie: Staționaritatea seriei

- regula de bază care guvernează nu se schimbă
- comportamentul viitor poate fi dedus pe baza trecutului
- avem suficiente observații din trecut pentru a înțelege procesul de bază.

Considerăm că  $y_t$  este un proces stochastic staționar cu media zero. Putem presupune că suntem la momentul  $n$  și suntem interesați de a prognoza sau previziona valorile acestui proces pentru câteva perioade din viitor, pe baza observațiilor din trecut. Istoria acestui proces este conținută într-o mulțime a informațiilor iar predicția va fi bazată pe această mulțime de informații. În practică, această mulțime este o mulțime finită  $\{y_n, y_{n-1}, \dots, y_{n-p}\}$ , reprezentând trecutul recent. Totuși, în dezvoltarea teoriei predicției, este util a se considera o mulțime a informațiilor infinită  $I_n = \{y_n, y_{n-1}, \dots, y_{n-p}, \dots\}$ , reprezentând întregul trecut.

Vom nota predicția lui  $y_{n+h}$ , care este făcută la momentul  $n$ , prin  $y_n(h)$  sau  $\hat{y}_{n+h}$ .

Vom spune că  **$n$  este originea**,  **$h$  este orizontul de timp** iar  $y_n(h)$  este **valoarea previzionată pentru  $y_{n+h}$  cu  $h$  perioade înainte**. În general, predictorul  $y_n(h)$  ( predictorul lui  $y_{n+h}$ , construit la timpul  $t$ ), este o funcție de variabilele din mulțimea  $I_t$ .

Definim **eroarea de previziune** (de prognoză) a lui  $y_{n+h}$ , diferența dintre valoarea reală și cea previzionată:  $e_n(h) = y_{n+h} - y_n(h) = y_{n+h} - \hat{y}_{n+h}$ . Ne așteptăm ca valoarea medie a acestei erori să fie:

$$E((y_{n+h} - \hat{y}_{n+h}) | I_n) = E(y_{n+h}) - \hat{y}_{n+h} = \hat{y}_{n+h} - \hat{y}_{n+h} = 0.$$

Varianța erorii de prognoză  $Var(e_n(h))$  este  $E((y_{n+h} - \hat{y}_{n+h})^2 | I_n)$ . Acesta este necesară pentru previziunile pe interval de încredere, care sunt mai utile decât o estimare punctuală.

Criteriul folosit în mod obișnuit pentru a aprecia performanța unui estimator sau predictor al unei variabile aleatoare este minimizarea pătratului erorii medii condiționate, de prognoză, adică:

$$\min E((y_{n+h} - y_n(h))^2 | I_n).$$

Vom folosi și una din notațiile:  $y_n(h) = E(y_{n+h} | I_n) = E_t(y_{n+h})$ .

$y_n(h)$  (sau  $\hat{y}_{n+h}$ ) va fi calculat din ecuația modelului, scrisă pentru  $y_{n+h}$ , în felul următor:

- Înlocuim toți parametrii necunoscuți prin valorile lor estimate.
- Înlocuim variabilele aleatoare  $y_1, y_2, \dots, y_n$  prin valorile lor observate.
- Înlocuim variabilele aleatoare  $y_{n+1}, y_{n+2}, \dots, y_{n+h-1}$  prin valorile lor predictate:  $\hat{y}_{n+1}, \hat{y}_{n+2}, \dots, \hat{y}_{n+h-1}$
- Înlocuim variabilele eroare  $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$  prin reziduuri
- Înlocuim variabilele eroare  $\varepsilon_{n+1}, \varepsilon_{n+2}, \dots, \varepsilon_{n+h-1}$  prin 0, adică media lor așteptată.

### Predicția cu ajutorul modelului MA(q)

Un proces MA(q) are o memorie doar de lungime q și aceasta limitează orizontul de prognoză.

De exemplu, presupunem că am estimat un model MA(2):

$$y_n = \mu + \varepsilon_n + \theta_1 \varepsilon_{n-1} + \theta_2 \varepsilon_{n-2}$$

Presupunem că ne bazăm pe  $n$  observații. Deoarece se presupune că parametrii sunt constanți în timp, dacă relația anterioară are loc la momentul  $n$ , ea va avea loc și la momentele  $n+1, n+2, \dots$ . Vom putea scrie relațiile:

$$y_{n+1} = \mu + \varepsilon_{n+1} + \theta_1 \varepsilon_n + \theta_2 \varepsilon_{n-1}$$

$$y_{n+2} = \mu + \varepsilon_{n+2} + \theta_1 \varepsilon_{n+1} + \theta_2 \varepsilon_n$$

$$y_{n+3} = \mu + \varepsilon_{n+3} + \theta_1 \varepsilon_{n+2} + \theta_2 \varepsilon_{n+1}$$

Ținem cont că toate informațiile până la momentul  $n$ , inclusiv cele de la momentul  $n$ , sunt cunoscute și disponibile. Realizarea de prognoze înseamnă a considera mediile condiționate de informațiile disponibile. Perturbațiile  $\varepsilon_{n+1}, \varepsilon_{n+2}, \dots$  nu sunt cunoscute la momentul  $n$ . Cea mai bună prognoză pentru media condiționată a lui  $\varepsilon_{n+1}$  este zero, adică  $E_n(\varepsilon_{n+1}) = E(\varepsilon_{n+1} | I_n) = 0$ , datorită ipotezelor procesului de zgomot alb. Vom obține:

$$\begin{aligned} h=1 \Rightarrow \hat{y}_{n+1} &= y_n(1) = E(y_{n+1} | I_n) = E(\mu + \varepsilon_{n+1} + \theta_1 \varepsilon_n + \theta_2 \varepsilon_{n-1}) \\ &= \mu + E(\varepsilon_{n+1}) + \theta_1 E(\varepsilon_n) + \theta_2 E(\varepsilon_{n-1}) = \mu + \theta_1 \varepsilon_n + \theta_2 \varepsilon_{n-1} \\ e_n(1) &= y_{n+1} - \hat{y}_{n+1} = \varepsilon_{n+1} \\ \text{Var}(e_n(1)) &= \text{Var}(\varepsilon_{n+1}) = \sigma^2 \end{aligned}$$

Un interval de încredere 95% este de forma:  $\hat{y}_{n+1} \pm 2\sigma$

$$\begin{aligned} h=2 \Rightarrow \hat{y}_{n+2} &= y_n(2) = E(y_{n+2} | I_n) = E(\mu + \varepsilon_{n+2} + \theta_1 \varepsilon_{n+1} + \theta_2 \varepsilon_n) \\ &= \mu + E(\varepsilon_{n+2}) + \theta_1 E(\varepsilon_{n+1}) + \theta_2 E(\varepsilon_n) = \mu + \theta_2 \varepsilon_n \\ e_n(2) &= y_{n+2} - \hat{y}_{n+2} = \varepsilon_{n+2} + \theta_1 \varepsilon_{n+1} \\ \text{Var}(e_n(2)) &= \text{Var}(\varepsilon_{n+2} + \theta_1 \varepsilon_{n+1}) = (1 + \theta_1^2) \sigma^2 \end{aligned}$$

Un interval de încredere 95% este de forma:  $\hat{y}_{n+1} \pm 2\sqrt{(1 + \theta_1^2)} \sigma^2$

$$\begin{aligned} h=3 \Rightarrow \hat{y}_{n+3} &= y_n(3) = E(y_{n+3} | I_n) = E(\mu + \varepsilon_{n+3} + \theta_1 \varepsilon_{n+2} + \theta_2 \varepsilon_{n+1}) \\ &= \mu + E(\varepsilon_{n+3}) + \theta_1 E(\varepsilon_{n+2}) + \theta_2 E(\varepsilon_{n+1}) = \mu \\ e_n(3) &= y_{n+3} - \hat{y}_{n+3} = \varepsilon_{n+3} + \theta_1 \varepsilon_{n+2} + \theta_2 \varepsilon_{n+1} \\ \text{Var}(e_n(3)) &= \text{Var}(\varepsilon_{n+3} + \theta_1 \varepsilon_{n+2} + \theta_2 \varepsilon_{n+1}) = (1 + \theta_1^2 + \theta_2^2) \sigma^2 \end{aligned}$$

Deoarece procesul MA(2) are o memorie de numai 2 perioade, toate predicțiile pentru 3 sau mai multe perioade în viitor, se reduc la parametrul de interceptare din model. Dacă în model nu există constantă, aceste prognoze vor fi 0.

$$\text{Am folosit faptul că: } E_n(\varepsilon_{n+j}) = E(\varepsilon_{n+j} | I_n) = \begin{cases} \varepsilon_{n+j}, & j \leq 0 \\ 0, & j > 0 \end{cases}$$

Pentru  $j \leq 0$  avem valori cunoscute iar pentru  $j > 0$  avem valori viitoare care au media 0.

### Predicția cu ajutorul modelului AR(p)

Un proces AR are memorie infinită, spre deosebire de un proces MA(q) care are memorie de numai q perioade. Considerăm că a fost estimat un model AR(2):  $y_t = \mu + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$

Vom apela, din nou, la presupunerea de stabilitate a parametrilor și vom putea scrie relațiile:

$$y_n = c + \phi_1 y_{n-1} + \phi_2 y_{n-2} + \varepsilon_n$$

$$y_{n+1} = c + \phi_1 y_n + \phi_2 y_{n-1} + \varepsilon_{n+1}$$

$$y_{n+2} = c + \phi_1 y_{n+1} + \phi_2 y_n + \varepsilon_{n+2}$$

$$y_{n+3} = c + \phi_1 y_{n+2} + \phi_2 y_{n+1} + \varepsilon_{n+3}.$$

Obținerea prognozei pentru o perioadă în viitor este simplă deoarece toate informațiile despre y sunt cunoscute la timpul n. Aplicăm operatorul de medie și considerăm  $E_n(\varepsilon_{n+1}) = E(\varepsilon_{n+1} | I_n) = 0$ .

$$h = 1 \Rightarrow \hat{y}_{n+1} = y_n(1) = E(y_{n+1} | I_n) = E(c + \phi_1 y_n + \phi_2 y_{n-1} + \varepsilon_{n+1}) = c + \phi_1 y_n + \phi_2 y_{n-1}$$

$$e_n(1) = y_{n+1} - \hat{y}_{n+1} = \varepsilon_{n+1} \Rightarrow \text{Var}((e_n(1))) = \text{Var}(\varepsilon_{n+1}) = \sigma^2$$

Un interval de încredere 95% este de forma:  $\hat{y}_{n+1} \pm 2\sigma$

$$h = 2 \Rightarrow \hat{y}_{n+2} = y_n(2) = E(y_{n+2} | I_n) = E(c + \phi_1 y_{n+1} + \phi_2 y_n + \varepsilon_{n+2}) = c + \phi_1 \hat{y}_{n+1} + \phi_2 y_n$$

$$e_n(2) = y_{n+2} - \hat{y}_{n+2} = c + \phi_1 (y_{n+1} - \hat{y}_{n+1}) + \varepsilon_{n+2} = c + \phi_1 \varepsilon_{n+1} + \varepsilon_{n+2}$$

$$\text{Var}(e_n(2)) = \text{Var}(c + \phi_1 \varepsilon_{n+1} + \varepsilon_{n+2}) = (1 + \phi_1^2)\sigma^2$$

Un interval de încredere 95% este de forma:  $\hat{y}_{n+1} \pm 2\sqrt{(1 + \phi_1^2)\sigma^2}$

$$h = 3 \Rightarrow \hat{y}_{n+3} = y_n(3) = E(y_{n+3} | I_n) = E(c + \phi_1 y_{n+2} + \phi_2 y_{n+1} + \varepsilon_{n+3}) = c + \phi_1 \hat{y}_{n+2} + \phi_2 \hat{y}_{n+1}$$

$$\begin{aligned} e_n(3) &= y_{n+3} - \hat{y}_{n+3} = c + \phi_1 y_{n+2} + \phi_2 y_{n+1} + \varepsilon_{n+3} - (c + \phi_1 \hat{y}_{n+2} + \phi_2 \hat{y}_{n+1}) = \\ &= \phi_1 (y_{n+2} - \hat{y}_{n+2}) + \phi_2 (y_{n+1} - \hat{y}_{n+1}) + \varepsilon_{n+3} \end{aligned}$$

### Predicția cu ajutorul unui model ARMA(2,2)

Considerăm un model ARMA(2,2):  $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$

Dorim o predicție la momentul n, peste 2 perioade în viitor, deci pentru h=2.

$$y_n = \phi_1 y_{n-1} + \phi_2 y_{n-2} + \varepsilon_n + \theta_1 \varepsilon_{n-1} + \theta_2 \varepsilon_{n-2}$$

La momentul n+1 avem ecuația:  $y_{n+1} = \phi_1 y_n + \phi_2 y_{n-1} + \varepsilon_{n+1} + \theta_1 \varepsilon_n + \theta_2 \varepsilon_{n-1}$

La momentul n+2 avem ecuația:  $y_{n+2} = \phi_1 y_{n+1} + \phi_2 y_n + \varepsilon_{n+2} + \theta_1 \varepsilon_{n+1} + \theta_2 \varepsilon_n$

$$\hat{y}_{n+2} = y_n(2) = E(y_{n+2} | I_n) = \phi_1 \hat{y}_{n+1} + \phi_2 y_n + \theta_2 \varepsilon_n$$

### Predicția cu ajutorul modelului ARMA(p,q)

Prognozele pot fi generate prin așa numita funcție de prognoză:

$$f_{n,h} = \sum_{i=1}^p \phi_i f_{n,h-i} + \sum_{j=1}^q \theta_j \varepsilon_{n+h-j}, \text{ unde } f_{n,h} = y_{n+h}, h \leq 0, \varepsilon_{n+h} = \varepsilon_{n+h}, h \leq 0 \text{ și } \varepsilon_{n+h} = 0, h > 0.$$

### Predicția folosind modele ARIMA(p,d,q)

Presupunem că seria  $y_1, y_2, \dots, y_n$  urmează un model general ARIMA(p,d,q), model ce poate fi rescris în funcție de valoarea curentă și de valorile anterioare ale lui  $\varepsilon_t$ :

$$y_t = \frac{\Theta(L)}{\Phi(L)\Delta^d} \varepsilon_t = \Psi_\infty(L) \varepsilon_t = (1 + \psi_1 L + \psi_2^2 L^2 + \dots) \varepsilon_t$$

Valoarea viitoare  $y_{n+h}$  este generată prin model astfel:

$$y_{n+h} = \varepsilon_{n+h} + \psi_1 \varepsilon_{n+h-1} + \psi_2 \varepsilon_{n+h-2} + \dots$$

Prognoza optimală a lui  $y_{n+h}$  este media condiționată  $y_n(h) = E(y_{n+h} | I_n) = f_{n,h}$ . Termenul de prognoză optimală este folosit în sensul că minimizează eroarea pătratică medie (MSE).

Dacă procesul este normal, un interval de încredere  $(1-\alpha)$  va fi  $[y_n(h) \pm z_{\alpha/2} \sqrt{\text{Var}(e_n(h))}]$ . Pentru  $h=1$  avem  $e_n(1) = y_{n+1} - y_n(1) = \varepsilon_{n+1}$ , deci  $\sigma_\varepsilon^2$  este varianța erorii de prognoză pentru o perioadă în viitor.